

Análisis Avanzado de Sistemas de Visión por Computador para el Diagnóstico Fitopatológico en Cucurbitáceas: Una Revisión Técnica de Datasets, Arquitecturas y Metodologías

El avance de la agricultura de precisión ha situado a la visión por computador en el centro de la innovación para la seguridad alimentaria global. En el caso específico de las cucurbitáceas, que incluyen cultivos de alto valor económico y nutricional como el zapallo (*Cucurbita moschata*, *Cucurbita pepo*), la calabaza, el pepino y la sandía, la identificación temprana de enfermedades foliares es un factor determinante para la estabilidad de los rendimientos.¹ La patología vegetal en estas especies es compleja; los síntomas de enfermedades fúngicas, bacterianas y virales a menudo se solapan en sus manifestaciones visuales, presentando patrones de clorosis, necrosis y deformaciones morfológicas que desafían tanto a los expertos humanos como a los algoritmos de clasificación automatizada.¹ Este reporte técnico examina exhaustivamente el estado del arte en la detección automática de enfermedades en cucurbitáceas, proporcionando un catálogo detallado de recursos de datos, una evaluación de arquitecturas de aprendizaje profundo y recomendaciones metodológicas para la implementación de sistemas robustos en entornos reales.

Contexto Fitopatológico y Desafíos en la Visión por Computador

Las cucurbitáceas son susceptibles a una amplia gama de patógenos que afectan principalmente el área fotosintética de la planta. El mildiu vellosa (*Pseudoperonospora cubensis*) y el oídio (*Podosphaera xanthii*) se encuentran entre las amenazas más persistentes, manifestándose como manchas amarillentas angulares y crecimientos polvorientos blanquecinos, respectivamente.² Los virus, como el virus del mosaico y el virus del enrollamiento de la hoja, alteran la estructura foliar y el patrón cromático, creando texturas moteadas y rugosidades que son difíciles de segmentar debido a la falta de bordes definidos.⁴ Desde la perspectiva de la visión por computador, estas patologías introducen desafíos significativos. Las imágenes capturadas en condiciones de campo presentan ruido ambiental, variaciones extremas de iluminación, sombras proyectadas por el dosel del cultivo y fondos heterogéneos que incluyen suelo, sistemas de riego y otras plantas.¹ Además, existe una alta variabilidad intra-clase, donde una misma enfermedad puede mostrar síntomas diferentes según la etapa de la infección o la variedad del zapallo, y una baja variabilidad inter-clase, donde deficiencias nutricionales pueden mimetizar los síntomas de una virosis.³ Por lo tanto, la transición de modelos entrenados en laboratorios hacia sistemas capaces de operar "en la

naturaleza" (*in-the-wild*) requiere no solo arquitecturas potentes, sino también estrategias de preprocesamiento y aumento de datos altamente especializadas.⁶

Repositorios de Datos Públicos para Cucurbitáceas

La disponibilidad de datos etiquetados es el pilar de cualquier proyecto de investigación en aprendizaje profundo. Para el estudio de las cucurbitáceas, se han identificado datasets que cubren desde imágenes de clasificación simple hasta anotaciones complejas de segmentación de píxeles.

Catálogo de Datasets Específicos y Afines

A continuación, se presenta una tabla comparativa de los recursos de datos más relevantes para el entrenamiento y validación de modelos en el contexto de la investigación de zapallos y cultivos afines.

Nombre del Dataset	Enlace / Referencia	Formato / Tamaño	Licencia	Enfermedades cubiertas	Notas de uso / Limitaciones
Cucurbit Leaf Disease Dataset	4	JPG / 4,121 imágenes (Original + Aug)	CC BY 4.0	Mildiu vellosos, virus del enrollamiento, mosaico, hojas sanas.	Publicado en 2025. Alta resolución, ideal para clasificación y fine-tuning.
Sweet Pumpkin Disease Recognition	5	JPG / 7,000 imágenes aumentadas	Mendeley Data	Mildiu, enrollamiento, mosaico, escarabajo rojo (<i>Red Beetle</i>), sana.	Específico para <i>Cucurbita moschata</i> . Incluye una clase para daño por insectos.
Combined Bottle Gourd & Zucchini	8	CSV, JPG / 23,000 imágenes	Mendeley Data	Mancha angular, antracnosis, mildiu,	Excelente para aprendizaje multi-tarea

				deficiencia de hierro, daño insectos.	y distinción entre nutrición y patología.
A Dataset for Bottle Gourd Leaf	¹¹	JPG / 1,119 imágenes (Nativo)	Mendeley Data	Antracnosis , virus del mosaico, Alternaria, mildiu, mancha angular.	Imágenes capturadas en iluminación natural y escenarios reales de campo.
PlantSeg (Subconjunto Cucurbit)	⁶	PNG (Máscaras) / >11,000 total	Zenodo / CC BY-NC-ND	Oídio (Mildiu polvoriento) , mildiu velloso.	Dataset de segmentación a nivel de píxel. Esencial para localización precisa.
PlantVillage (Squash/Cucurbit)	¹³	JPG / Estandarizado	Abierta	Oídio, sana.	Entorno controlado. Útil como base para pre-entrenamiento inicial.

Análisis de la Calidad y Estructura de los Datos

El análisis de estos datasets revela una tendencia hacia la complejidad multiclase. El dataset de *Sweet Pumpkin* ⁵ es particularmente valioso por su enfoque en la variedad *Cucurbita moschata*, común en regiones tropicales y subtropicales. La inclusión del escarabajo rojo como clase distinta reconoce la importancia de los vectores bióticos en la propagación de enfermedades. Por otro lado, el dataset combinado ⁸ aborda una de las mayores debilidades de los modelos previos: la confusión entre el estrés abiótico (deficiencia de hierro) y las infecciones, lo que permite desarrollar sistemas de diagnóstico más precisos para la toma de decisiones agronómicas.

Para proyectos que requieren detección de objetos o segmentación, el recurso PlantSeg⁶ es fundamental. A diferencia de los datasets de clasificación de imagen completa, PlantSeg proporciona máscaras que delimitan exactamente el área de la lesión. Esto permite entrenar modelos que no solo digan qué enfermedad tiene la planta, sino que también cuantifiquen el porcentaje de área foliar afectada, una métrica crítica para determinar el umbral económico de aplicación de tratamientos.¹²

Arquitecturas de Modelos Recomendadas

La selección de la arquitectura debe responder a un compromiso entre la precisión del diagnóstico y la eficiencia en la inferencia, especialmente para aplicaciones que se desplegarán en dispositivos con recursos limitados como sensores IoT o teléfonos inteligentes.¹⁶

Redes Neuronales Convolucionales (CNN)

Las CNN continúan siendo la base de la mayoría de los sistemas de visión agrícola debido a su capacidad para extraer características espaciales locales.

- **ResNet (Residual Networks):** Utiliza conexiones de salto para evitar el desvanecimiento del gradiente, permitiendo entrenar redes muy profundas. Es el estándar para el aprendizaje por transferencia.¹⁷
- **EfficientNet:** Introduce un método de escalado compuesto que equilibra profundidad, ancho y resolución. EfficientNet-B3 ha demostrado un rendimiento superior en la clasificación de enfermedades de zapallo, alcanzando precisiones reportadas de hasta el 96% en configuraciones híbridas.¹
- **MobileNet (V2/V3):** Optimizada para dispositivos móviles mediante el uso de convoluciones separables en profundidad. Su tamaño compacto (~40 MB) la hace ideal para despliegue en campo con baja latencia.¹⁷

Vision Transformers (ViT) y Modelos Híbridos

Los Vision Transformers han emergido como una alternativa potente a las CNN al utilizar mecanismos de autoatención para capturar dependencias globales en la imagen.¹⁶ Sin embargo, su entrenamiento desde cero requiere volúmenes de datos masivos. La investigación actual favorece los modelos híbridos que combinan la extracción de características locales de las CNN con el modelado de largo alcance de los Transformers.¹⁶

Un ejemplo destacado de esta tendencia es la arquitectura **DualFusion-CBAM-Stochastic**, diseñada específicamente para la clasificación de patologías en *Cucurbita pepo*.¹ Esta red integra:

1. **DenseNet121** como columna vertebral para capturar texturas finas mediante conectividad densa.
2. **EfficientNetB3** para la extracción de características contextuales multiescala.
3. **Módulo de Atención de Bloque Convolucional (CBAM)**, que aplica atención secuencial de canal y espacial para resaltar las regiones de la lesión foliar y suprimir el ruido del fondo.¹
4. **Profundidad Estocástica**, que mejora la generalización mediante el bypass aleatorio de

capas durante el entrenamiento, reduciendo el sobreajuste en datasets pequeños.¹

Modelos Recomendados para el Investigador

Arquitectura	Framework	Ventajas	Desventajas	Enlace a Implementación / Tutorial
EfficientNetV2 B3	TensorFlow / PyTorch	Balance óptimo entre precisión y velocidad; excelente para fine-tuning. ¹³	Requiere hardware moderno para entrenamiento eficiente.	(https://keras.io/api/applications/efficientnet_v2/)
MobileNetV3-Large	PyTorch / TFLite	Diseñada para el borde; alta eficiencia energética y baja latencia. ¹⁸	Ligeramente menos precisa que modelos pesados en lesiones pequeñas.	(https://pytorch.org/vision/stable/models.html)
YOLOv8 / YOLOv11	PyTorch (Ultralytics)	Estado del arte en detección y segmentación en tiempo real. ²⁷	Requiere anotaciones precisas de cajas o polígonos.	Ultralytics GitHub
ConvNeXt-Tiny	PyTorch	Combina la simplicidad de las CNN con las lecciones de diseño de los Transformers. ¹⁸	Menos común en tutoriales introductorios.	(https://github.com/huggingface/pytorch-image-models)

Comparativa: Enfoques Clásicos vs. Deep Learning

Para un proyecto de nivel Master, es fundamental contrastar los métodos modernos con las técnicas clásicas de procesamiento de imágenes para justificar la complejidad del modelo propuesto.

Procesamiento de Imágenes Tradicional

Los enfoques clásicos dependen de la extracción manual de características (*handcrafted features*). Utilizando herramientas como **OpenCV**, el flujo de trabajo típico incluye:

- **Segmentación:** Métodos de umbralización (Otsu), segmentación basada en color en espacios HSV o Lab, y algoritmos de cuenca hidrográfica (*Watershed*) para aislar la hoja del fondo.²⁹
- **Extracción de Características:** Descriptores de textura como la Matriz de Co-ocurrencia de Niveles de Gris (GLCM) y Patrones Binarios Locales (LBP) para capturar la rugosidad de las lesiones. Descriptores de color mediante histogramas y momentos de color.³
- **Clasificación:** Algoritmos como Máquinas de Soporte Vectorial (SVM), K-Vecinos más Cercanos (KNN) o Bosques Aleatorios (Random Forest).⁷

La principal ventaja de estos métodos es su **interpretabilidad** y su capacidad para funcionar en hardware de muy baja potencia (por ejemplo, microcontroladores). Sin embargo, son extremadamente sensibles a las condiciones de iluminación y fallan al generalizar entre diferentes especies de cucurbitáceas debido a la variabilidad natural de la estructura de la hoja.³

Superioridad del Deep Learning

A diferencia de los métodos clásicos, las redes neuronales realizan un aprendizaje de extremo a extremo (*end-to-end*). El modelo aprende automáticamente qué filtros espaciales son más relevantes para distinguir, por ejemplo, el micelio blanco del oídio del patrón amarillento del mildiu vellosa.³ Los resultados experimentales muestran que mientras un clasificador SVM con características GLCM puede alcanzar un 93-97% en condiciones controladas, su precisión cae drásticamente en campo, mientras que modelos como YOLO o DenseNet mantienen una robustez superior gracias a su capacidad de aprender invariancias espaciales y semánticas.¹⁷

Proyectos e Investigaciones Similares en Cucurbitáceas

El estudio de casos previos proporciona una hoja de ruta metodológica y benchmarks para la comparación de resultados.

Título de la Investigación	Autores / Año	Enlace / Referencia	Hallazgos clave	Disponibilidad
AI-powered detection of pumpkin leaf diseases using DualFusion-CB	Chen et al. / 2025-26	¹	Logra 96% de precisión combinando DenseNet y EfficientNet	Datos de 2,000 imágenes descritos.

AM			con atención CBAM.	
PlantSeg: A Large-Scale In-the-wild Dataset for Plant Disease Segmentation	Wei et al. / 2025	6	Presenta el dataset más robusto para segmentación en condiciones reales.	Código y datos en GitHub/Zenodo .
Leaf disease detection using YOLOv7 and YOLOv8	Jafar et al. / 2024	28	Evalúa la velocidad y precisión de modelos YOLO en entornos complejos.	Metodología reproducible.
LeafGAN: An Effective Data Augmentation for Plant Disease Diagnosis	Zhu et al. / 2021	34	Usa GANs para generar imágenes sintéticas de enfermedades en pepino, mejorando la precisión en un 7.4%.	Código disponible en GitHub.
Efficient Detection of Cucurbita Pepo Leaf Diseases using YOLOv7	Selvaraj et al. / 2025	2	Clasificación exitosa de 4 enfermedades comunes en zapallito mediante YOLOv7.	Publicación académica (SciTePress).

Hallazgos Clave de la Literatura Reciente

Una lección recurrente en estas investigaciones es la importancia de la **explicabilidad**. Proyectos como AgriCure integran técnicas de AI Explicable (XAI) como Grad-CAM o LIME para generar mapas de calor que indican qué áreas de la hoja están influyendo en la predicción del modelo.¹³ Esto es vital para que el agrónomo confíe en el sistema, asegurándose de que el

modelo está mirando la lesión real y no un artefacto del fondo o una sombra. Otro hallazgo crítico es la eficacia del **aprendizaje por conjunto** (*ensemble learning*). Combinar las predicciones de modelos basados en VGG, ResNet e Inception mediante técnicas de votación puede elevar la precisión por encima del 99%, superando las limitaciones de cualquier modelo individual en clases específicas que presenten síntomas sutiles.²⁹

Recomendaciones Técnicas para el Pipeline de Investigación

Para un proyecto de nivel Master, el pipeline debe ser riguroso y seguir las mejores prácticas de la comunidad de visión por computador agrícola.

Estrategia de Preprocesamiento y Limpieza

El primer paso es la **estandarización de la imagen**. Las imágenes deben redimensionarse a una resolución consistente (comúnmente 224×224 o 256×256 píxeles). Es fundamental realizar una **corrección de color** si se dispone de una carta de referencia (como MacBeth ColorChecker) para mitigar el impacto de las diferentes temperaturas de color de la luz solar a lo largo del día.³⁵

La normalización es obligatoria: los valores de los píxeles (0-255) deben escalarse al rango

onormalizarseutilizandolamedia ydesviaciónestándardeldatasetImageNetsiseutilizaaprendizajeportransferencia[37, 38] :

$$x_{\text{norm}} = \frac{x - \mu_{\text{ImageNet}}}{\sigma_{\text{ImageNet}}}$$

Aumento de Datos Específico para Hojas

Dada la escasez de datos masivos en cultivos específicos como el zapallo, el aumento de datos sintético es la técnica más efectiva para prevenir el sobreajuste. Se recomiendan dos niveles de aumento:

1. **Aumento Geométrico:** Rotaciones (hasta 360°), volteos horizontales y verticales, y zoom aleatorio. Las hojas de las cucurbitáceas no tienen una orientación "arriba-abajo" fija en la naturaleza, por lo que estas transformaciones son biológicamente válidas.²¹
2. **Aumento de Textura y Ruido:** Inserción de ruido gaussiano, desenfoque de movimiento y variaciones de brillo/contraste para simular condiciones meteorológicas adversas o cámaras de baja calidad.²⁰
3. **Generación de Datos con GANs:** Si el dataset es muy pequeño, herramientas como **LeafGAN** pueden generar nuevas imágenes de hojas enfermas a partir de hojas sanas, preservando la estructura venosa de la planta original.³⁴

Manejo de la Escasez de Datos: Transfer Learning y Domain Adaptation

No se recomienda entrenar modelos desde cero. En su lugar, se deben emplear estrategias de adaptación:

- **Fine-tuning:** Cargar un modelo pre-entrenado en ImageNet, congelar las capas iniciales (que detectan bordes y texturas genéricas) y re-entrenar las capas finales con el dataset de cucurbitáceas.⁹
- **Domain-Specific Pre-training:** Entrenar primero en un dataset agrícola general grande (como PlantVillage con 54,000 imágenes) y luego realizar el ajuste fino en el dataset específico de zapallo. Esto reduce el "gap de dominio" significativamente más que usar solo ImageNet.⁹
- **Few-shot Learning (FSL):** En casos donde solo se tienen 5 o 10 imágenes de una enfermedad rara, técnicas como el aprendizaje meta-mapeado o el uso de redes siamesas permiten que el modelo aprenda a distinguir clases nuevas basándose en la similitud de características.²²

Métricas de Evaluación Adecuadas

Para el diagnóstico de enfermedades, la precisión global (*accuracy*) puede ser engañosa si el dataset está desbalanceado (por ejemplo, muchas más hojas sanas que enfermas). Se deben reportar obligatoriamente:

- **Recall (Sensibilidad):** Mide la capacidad del modelo para encontrar todos los casos de enfermedad. Un falso negativo (omitir una enfermedad) es mucho más costoso que un falso positivo.²¹
- **F1-Score:** La media armónica entre precisión y recall, ideal para una evaluación balanceada.¹⁸
- **Matriz de Confusión:** Fundamental para identificar si el modelo confunde sistemáticamente dos enfermedades específicas, como el mosaico y el enrollamiento foliar.⁷

Herramientas y Librerías Python Recomendadas

Para implementar el pipeline completo, se sugieren las siguientes bibliotecas del ecosistema Python, compatibles con entornos estándar como Google Colab:

- **Procesamiento y Carga:** OpenCV para manipulación de bajo nivel, PIL (Pillow) para manejo de archivos de imagen, y Numpy para operaciones matriciales.³⁷
- **Aumento de Datos:** Albumentations es la librería más eficiente y versátil para tareas de visión agrícola, soportando imágenes, máscaras y bounding boxes simultáneamente.⁴⁵
- **Modelado y Entrenamiento:** PyTorch (preferido en investigación por su flexibilidad) o TensorFlow/Keras (excelente para despliegue rápido y uso de pre-entrenados).⁹
- **Fenotipado Especializado:** PlantCV. Es una librería de código abierto diseñada específicamente para el análisis de imágenes de plantas, ofreciendo módulos para corrección de color, segmentación por umbrales adaptativos y análisis morfológico sin necesidad de IA compleja.³⁵
- **Seguimiento de Experimentos:** Scikit-learn para validación cruzada estratificada y métricas avanzadas.¹⁸

Consideraciones para el Despliegue en Campo

La transición del modelo del laboratorio al campo implica considerar la **complejidad computacional**. Modelos como DualFusion-CBAM-Stochastic ofrecen una precisión alta, pero su arquitectura dual puede ser pesada para un dispositivo móvil. Si el objetivo es una aplicación móvil, el investigador debe considerar la **cuantización del modelo** (convertir pesos de 32 bits a 8 bits) y el uso de formatos optimizados como **TensorFlow Lite (TFLite)** u **ONNX**.¹⁷

Además, la robustez frente a la "deriva de dominio" (*domain shift*) es esencial. Un modelo entrenado con imágenes de zapallos en Bangladesh⁵ puede no funcionar perfectamente en cultivos de América Latina debido a diferencias en la morfología de las variedades locales y las condiciones de luz. Por lo tanto, se recomienda recolectar un pequeño subconjunto de datos locales para realizar un ajuste fino final (*local fine-tuning*) antes del despliegue masivo.³

Síntesis de Recomendaciones para el Proyecto de Investigación

Para asegurar el éxito de un proyecto de nivel Master en la detección de enfermedades de *Cucurbita spp.*, se proponen las siguientes directrices:

1. **Priorizar la Calidad del Dato:** Utilizar el dataset de *Sweet Pumpkin*⁵ como base principal y suplementar con *PlantSeg*⁶ si se desea realizar segmentación de lesiones.
2. **Adoptar Arquitecturas Híbridas:** Implementar una red que combine las fortalezas de extracción local de una CNN (como EfficientNet o DenseNet) con un módulo de atención (CBAM) para filtrar el ruido de fondo, siguiendo el ejemplo del modelo *DualFusion*.¹
3. **Implementar un Pipeline de Aumento Robusto:** Utilizar Albumentations para aplicar transformaciones que simulen la variabilidad real del campo, incluyendo cambios en la iluminación y desenfoques por movimiento de la cámara.⁴⁵
4. **Validar con Múltiples Métricas:** No reportar solo precisión. El uso de F1-Score y matrices de confusión proporcionará la profundidad analítica requerida en una tesis de grado.¹⁸
5. **Documentar la Reproducibilidad:** Basar el código en repositorios abiertos como el de *PlantSeg* o los tutoriales de *PlantCV* para asegurar que la metodología sea auditable por otros investigadores.¹²

El campo de la fitopatología computacional en cucurbitáceas está en una fase de rápida evolución. La integración de modelos más pequeños pero más inteligentes, capaces de aprender de pocos ejemplos y de explicar sus decisiones, representa el futuro de la protección de cultivos asistida por inteligencia artificial.²²

Obras citadas

1. AI-powered detection of pumpkin leaf diseases using DualFusion ..., fecha de acceso: abril 21, 2026, <https://pmc.ncbi.nlm.nih.gov/articles/PMC12903779/>
2. Efficient Detection of Cucurbit Pepo Leaf Diseases Using Advanced Image Processing Techniques - SciTePress, fecha de acceso: abril 21, 2026, <https://www.scitepress.org/PublishedPapers/2025/136220/>
3. A Cross-Crop and Cross-Regional Generalized Deep Learning Framework for

- Intelligent Disease Detection and Economic Decision Support in Horticulture - MDPI, fecha de acceso: abril 21, 2026, <https://www.mdpi.com/2311-7524/11/11/1397>
4. Cucurbit Leaf Disease Dataset - Mendeley Data, fecha de acceso: abril 21, 2026, <https://data.mendeley.com/datasets/whw368mjvv/1>
 5. Sweet Pumpkin Disease Recognition Dataset - Mendeley Data, fecha de acceso: abril 21, 2026, <https://data.mendeley.com/datasets/7397w9h5tb>
 6. A Large-Scale In-the-wild Dataset for Plant Disease Segmentation ..., fecha de acceso: abril 21, 2026, <https://pmc.ncbi.nlm.nih.gov/articles/PMC12891534/>
 7. A Comprehensive Survey on Machine Learning and Deep Learning Techniques for Crop Disease Prediction in Smart Agriculture - ResearchGate, fecha de acceso: abril 21, 2026, https://www.researchgate.net/publication/381130302_A_Comprehensive_Survey_on_Machine_Learning_and_Deep_Learning_Techniques_for_Crop_Disease_Prediction_in_Smart_Agriculture
 8. A Combined Dataset of Bottle Gourd, Zucchini, and Papaya Leaf Diseases for Machine Learning and Deep Learning Applications - Mendeley Data, fecha de acceso: abril 21, 2026, <https://data.mendeley.com/datasets/c34t55y9gj>
 9. Assessing the performance of domain-specific models for plant leaf disease classification: a comprehensive benchmark of transfer-learning on open datasets - PMC, fecha de acceso: abril 21, 2026, <https://pmc.ncbi.nlm.nih.gov/articles/PMC12125250/>
 10. Cucurbit Leaf Disease Dataset - Kaggle, fecha de acceso: abril 21, 2026, <https://www.kaggle.com/datasets/bimsarakumarasinghe/cucurbit-leaf-disease-dataset>
 11. A Dataset for Classification of Bottle Gourd Leaf Diseases - Mendeley Data, fecha de acceso: abril 21, 2026, <https://data.mendeley.com/datasets/m9nmyp7r6h>
 12. tqwei05/PlantSeg: A Large-Scale In-the-wild Dataset for ... - GitHub, fecha de acceso: abril 21, 2026, <https://github.com/tqwei05/PlantSeg>
 13. Cucurbit Foliar Disease Identification with Deep Learning and XGBoost: A ResNet50 Approach - R Discovery, fecha de acceso: abril 21, 2026, <https://discovery.researcher.life/article/cucurbit-foliar-disease-identification-with-deep-learning-and-xgboost-a-resnet50-approach/e9d022146e493335a310f98521ac5376>
 14. Fine-grained identification of greenhouse crop leaf diseases based on reconstruction-generation network - PMC, fecha de acceso: abril 21, 2026, <https://pmc.ncbi.nlm.nih.gov/articles/PMC12970908/>
 15. plant-disease · GitHub Topics, fecha de acceso: abril 21, 2026, <https://github.com/topics/plant-disease>
 16. Vision Transformer and CNN-Based Models for Image Analysis of Plant Diseases: An Approach for Agricultural Decision Support Systems, fecha de acceso: abril 21, 2026, <https://ispecjournal.com/index.php/ispecjas/article/view/915>
 17. Disease diagnosis in banana leaves: a review on AI powered techniques - PeerJ, fecha de acceso: abril 21, 2026, <https://peerj.com/articles/cs-3310/>
 18. A COMPARATIVE STUDY OF CNN AND TRANSFORMER-BASED ..., fecha de

acceso: abril 21, 2026,

<https://www.firatakademi.com/articleDetails.asp?lang=2&article=FIRAT-AKADEMI-8774-5786>

19. Comparison of ResNet CNN and Optimized Vision Transformer Model for Classification of Dried Moringa Leaf Quality | Jurnal Sistem Informasi dan Komputer Terapan Indonesia (JSIKTI) - INFOTEKS, fecha de acceso: abril 21, 2026, <https://www.infoteks.org/journals/index.php/jsikti/article/view/213>
20. Plant Leaf Disease Detection Using Deep Learning: A Multi-Dataset Approach - MDPI, fecha de acceso: abril 21, 2026, <https://www.mdpi.com/2571-8800/8/1/4>
21. Improving the Accuracy of Plant Leaf Disease Detection and Classification in Images of Plant Leaves: - DiVA portal, fecha de acceso: abril 21, 2026, <https://www.diva-portal.org/smash/get/diva2:1778236/FULLTEXT03.pdf>
22. A Domain-Adapted Lightweight Ensemble for Resource-Efficient Few-Shot Plant Disease Classification - arXiv, fecha de acceso: abril 21, 2026, <https://arxiv.org/html/2512.13428v1>
23. PD-TR: End-to-end plant diseases detection using a transformer - ResearchGate, fecha de acceso: abril 21, 2026, https://www.researchgate.net/publication/381317622_PD-TR_End-to-end_plant_diseases_detection_using_a_transformer
24. Revolutionizing plant disease detection with Vision Transformers and Convolutional Neural Networks approaches! - PI@ntNet - PlantNet, fecha de acceso: abril 21, 2026, <https://plantnet.org/en/2025/02/10/revolutionizing-plant-disease-detection-with-vision-transformers-and-convolutional-neural-networks-approaches/>
25. AI-powered detection of pumpkin leaf diseases using DualFusion-CBAM-stochastic for yield protection and precision agriculture - ScienceOpen, fecha de acceso: abril 21, 2026, <https://www.scienceopen.com/document?vid=d845db97-ccb3-4c6e-8c5a-5398630c3fe4>
26. From laboratory to field: cross-domain few-shot learning for crop disease identification in the field - PMC, fecha de acceso: abril 21, 2026, <https://pmc.ncbi.nlm.nih.gov/articles/PMC11688362/>
27. leaf-diseases-detection · GitHub Topics, fecha de acceso: abril 21, 2026, <https://github.com/topics/leaf-diseases-detection>
28. An efficient plant disease detection using transfer learning approach - PMC, fecha de acceso: abril 21, 2026, <https://pmc.ncbi.nlm.nih.gov/articles/PMC12125318/>
29. Plant Leaf Disease Detection Using Ensemble Learning and Explainable AI - IEEE Xplore, fecha de acceso: abril 21, 2026, <https://ieeexplore.ieee.org/iel8/6287639/10380310/10729231.pdf>
30. Tutorial: PSII Image Pipeline - PlantCV, fecha de acceso: abril 21, 2026, https://docs.plantcv.org/en/v1.1/psii_tutorial/
31. Classification of Multi Diseases in Apple Plant Leaves - Diva-portal.org, fecha de acceso: abril 21, 2026, <https://www.diva-portal.org/smash/get/diva2:1535603/FULLTEXT02.pdf>
32. Plant Disease Detection Using a Simple, Lightweight and Efficient Machine

- Learning System. - ResearchGate, fecha de acceso: abril 21, 2026, https://www.researchgate.net/publication/399213073_Plant_Disease_Detection_Using_a_Simple_Lightweight_and_Efficient_Machine_Learning_System
33. AI-powered detection of pumpkin leaf diseases using DualFusion-CBAM-stochastic for yield protection and precision agriculture - PubMed, fecha de acceso: abril 21, 2026, <https://pubmed.ncbi.nlm.nih.gov/41695538/>
 34. IyatomiLab/LeafGAN - GitHub, fecha de acceso: abril 21, 2026, <https://github.com/IyatomiLab/LeafGAN>
 35. Tutorials — PlantCV, fecha de acceso: abril 21, 2026, <https://plantcv.org/tutorials>
 36. PlantCV v4: Image analysis software for high-throughput plant phenotyping - bioRxiv, fecha de acceso: abril 21, 2026, <https://www.biorxiv.org/content/10.1101/2025.11.19.689271v1.full.pdf>
 37. Python OpenCV Leaf Disease Detection - Safeguard Your Green Haven, fecha de acceso: abril 21, 2026, <https://pythongeeks.org/python-opencv-leaf-disease-detection/>
 38. Plant-Disease-Detection/Plant_Disease_Detection.ipynb at main - GitHub, fecha de acceso: abril 21, 2026, https://github.com/zawrabh/Plant-Disease-Detection/blob/main/Plant_Disease_Detection.ipynb
 39. GitHub - aleju/imgaug: Image augmentation for machine learning experiments., fecha de acceso: abril 21, 2026, <https://github.com/aleju/imgaug>
 40. PLDC-Net: A Domain-Specific Base Model for Plant Leaf Disease Classification Domain Adaptation Tasks - PMC, fecha de acceso: abril 21, 2026, <https://pmc.ncbi.nlm.nih.gov/articles/PMC13088867/>
 41. Few-shot crop disease recognition using sequence- weighted ensemble model-agnostic meta-learning - PMC, fecha de acceso: abril 21, 2026, <https://pmc.ncbi.nlm.nih.gov/articles/PMC12364850/>
 42. Prune-FSL: Pruning-Based Lightweight Few-Shot Learning for Plant Disease Identification, fecha de acceso: abril 21, 2026, <https://www.mdpi.com/2073-4395/14/9/1878>
 43. Transfer Learning for Multi-Crop Leaf Disease Image Classification using Convolutional Neural Network VGG - ResearchGate, fecha de acceso: abril 21, 2026, https://www.researchgate.net/publication/357652094_Transfer_Learning_for_Multi-Crop_Leaf_Disease_Image_Classification_using_Convolutional_Neural_Network_VGG
 44. vsmidhun21/Leaf-Disease-Detection - GitHub, fecha de acceso: abril 21, 2026, <https://github.com/vsmidhun21/Leaf-Disease-Detection>
 45. alumentations - PyPI, fecha de acceso: abril 21, 2026, <https://pypi.org/project/alumentations/>
 46. Alumentations: Fast and Flexible Image Augmentations - MDPI, fecha de acceso: abril 21, 2026, <https://www.mdpi.com/2078-2489/11/2/125>
 47. What are the best libraries for implementing data augmentation? - Milvus, fecha de acceso: abril 21, 2026,

<https://milvus.io/ai-quick-reference/what-are-the-best-libraries-for-implementing-data-augmentation>

48. LeafNet: A Large-Scale Dataset and Comprehensive Benchmark for Foundational Vision-Language Understanding of Plant Diseases - arXiv, fecha de acceso: abril 21, 2026, <https://arxiv.org/html/2602.13662v3>